

První úkol — Časové řady

Kurz: BPE_CARA 2026 | Termín odovzdania: 13. apríl 2026

Riešiteľ: Mgr. Dana Kozáková

Príprava dát

Analyzovaný časový rad: mesačný menový kurz EUR/USD. Dáta boli stiahnuté z databázy Federal Reserve Economic Data (FRED) prostredníctvom API (séria DEXUSEU), za obdobie 2000/01/01 – 2025/12/01, čo predstavuje 312 mesačných pozorovaní.

Zdroj: <https://fred.stlouisfed.org/series/DEXUSEU>

Príklad 1: Transformácia a vizualizácia

1.1 Voľba transformácie


Pre menový kurz EUR/USD som zvolila transformáciu log-diferencií ($\Delta \ln St = \ln St - \ln St-1$), najmä preto, že to má ekonomický význam. A taktiež preto, aby som dosiahla stacionaritu.


- Kurz je multiplikatívny proces — zaujímajú nás percentuálne zmeny, nie absolútne zmeny
- Log-diferencie sú symetrické pre pohyby nahor aj nadol.
- Rozptyl log-diferencií nezávisí od úrovne kurzu, tým sa odstráni heteroskedasticita.

Pri obyčajných diferenciách je problém s interpretovateľnosťou, samotný rad vyzerá byť stacionárny. Log-diferencie sú štandardom pre finančné ceny a menové kurzy.

1.2 Vizualizácia

Úroveň kurzu EUR/USD vykazuje zjavnú nestacionaritu — rad nemá konštantnú strednú hodnotu ani rozptyl a nevykazuje tendenciu návratu k priemeru. Naopak, diferencie aj log-diferencie kolíšu symetricky okolo nuly s relatívne stabilným rozptylom, čo naznačuje stacionaritu transformovaného radu.






1.3 ACF a PACF

ACF úroveň: pomaly klesajúca, vysoko významná až do lagu 40 — klasický znak nestacionarity.

PACF úroveň: jeden dominantný hrot na lague 1 (približne 1.0), potom nič — typický vzor náhodnej prechádzky.

ACF log-diferencií: jeden významný hrot na lague 1 (cca +0.30), potom všetky hodnoty v konfidenčnom pásme — naznačuje to MA(1).

PACF log-diferencií: analogicky jeden hrot na lague 1 ($\approx +0.30$) — naznačuje to AR(1). Na základe oboch korelačných funkcií je transformovaný rad vhodný na modelovanie pomocou ARMA. Vidíme pokles do konfidenčného intervalu po lague 1



Príklad 2: ARMA modely a diagnostika

2.1 Odhadnuté modely

Na základe ACF a PACF log-diferencií boli odhadnuté tri modely:

- AR(1), MA(1) a ARMA(1,1).

Modely boli odhadnuté metódou maximálnej vierohodnosti pomocou knižnice statsmodels v Pythone na celej transformovanej rade (311 pozorovaní po diferencovaní).

Pri všetkých troch modeloch vidíme:

- **konštanta** takmer 0, štatisticky nevýznamná. Teda priemer log-diferencií nie je štatisticky významný od nuly. Kurz nemá dlhodobý trend – ani nahor, ani nadol.
- **sigma2** je pre všetky modely 0,0004, štatisticky významné. Teda typická mesačná variabilita je $0,02 = \pm 2\%$
- **koeficient pre AR** časť procesu: v AR(1) je 0,3065 a štatisticky významný. Avšak v ARMA(1) je hodnota 0,0255 štatisticky nevýznamná
- **koeficient pre MA** časť procesu sú podobné v MA(1) aj ARMA(1, 1): 0,3219 a 0,3079. V oboch sú štatisticky významné, teda minulé šoky majú preukázateľný vplyv na aktuálnu zmenu kurzu. Časť efektu pretrváva do nasledujúceho mesiaca. Existuje mierna zotrvačnosť v zmenách kurzu.
- zaujímavé je ARMA(1,1): tu je ar.L1 nesignifikantný, teda relevantná podľa tohto modelu je práve MA zložka, nie AR.

Tabuľka 1: Koeficienty odhadnutých modelov


Model	AR(1)		MA(1)		ARMA(1,1)	
	coef	p	coef	p	coef	p
const	0,0004	0,7975	0,0005	0,7706	0,0005	0,7758
ar.L1	0,3065	0,0000			0,0255	0,8446
ma.L1			0,3219	0,0000	0,3079	0,0170
sigma	0,0004	0,0000	0,0004	0,0000	0,0004	0,0000

2.2 Diagnostické testy

Ljung-Box test (H_0 : reziduá sú biely šum) nebol zamietnutý pri žiadnom modeli ani pri žiadnom testovanom lagu. Všetky p-hodnoty sú vysoko nad hladinou 0,05. Teda reziduá všetkých troch modelov sú biely šum.

Tabuľka 2: Ljung-Box test

Model	AR(1)	MA(1)	ARMA(1,1)
LB(6) p	0,494	0,698	0,704
LB(12) p	0,727	0,790	0,800
LB(24) p	0,678	0,664	0,676



Pre všetky 3 modely vyzerajú reziduá ako biely šum – náhodné hodnoty okolo nuly. Mierne sa líši rozptyl v prvej a druhej polovici obdobia. Autokorelogram nemá žiadne významné hroty. Možno teda povedať, že všetky tri modely sú porovnateľne dobré.

Stabilita a invertibilita:

Všetky odhadnuté modely sú stabilné a invertibilné. AR aj MA korene ležia v absolútnej hodnote mimo jednotkového kruhu. Podmienky sú splnené pre všetky tri modely:


Tabuľka 3: Jednotkové korene modelov

Korene pre model	AR(1)	MA(1)	ARMA(1,1)
AR koreň	3,263		39,272
MA koreň		-3,107	-3,248

2.3 Kvalita vyrovnania

Vyrovnané hodnoty všetkých troch modelov tesne sledujú skutočný rad — rozdiely medzi modelmi sú minimálne. RMSE sa pohybuje okolo 0.0206 pre všetky modely, čo zodpovedá priemernej absolútnej odchýlke mesačného výnosu cca 1.6 percentuálneho bodu.

Log-diferenciál Eurybor, skutočné vs. vyrovnané hodnoty



Tabuľka 4: Diagnostika modelov

Model	AR(1)	MA(1)	ARMA(1,1)
AIC	-1524,3	-1526,4	-1524,6
BIC	-1513,1	-1515,2	-1509,6
RMSE	0,021	0,021	0,021
MAE	0,016	0,016	0,016

2.4 Výber najlepšieho modelu

Na základe AIC a BIC bol ako najlepší in-sample model vybraný MA(1). ARMA(1,1) nepridáva oproti MA(1) štatisticky ani prakticky významnú hodnotu — extra parameter nezlepšuje vyrovnanie (BIC ARMA(1,1) = -1509.64 vs. MA(1) = -1515.22). Princíp úspornosti hovorí v prospech jednoduchšieho modelu. Hodnoty RMSE a MAE sú prakticky identické naprieč všetkými modelmi.

Príklad 3: Predikcia z ARMA modelov

3.1 – 3.3 Rekurzívne predikcie a porovnanie modelov

Rekurzívne predikcie pre horizonty $h = 1, 2, 3, 4$ boli získané pre oba typy okna (expanding a rolling) s počiatočnou dĺžkou trénovacej vzorky 252 pozorovaní a out-of-sample periódou 60 mesiacov. Ako miera predikčnej výkonnosti bolo použité RMSE.

Tabuľka 5: RMSE — expanding okno

Model	h=1	h=2	h=3	h=4
AR(1)	0,0157	0,0170	0,0171	0,0171
MA(1)	0,0157	0,0170	0,0171	0,0171
ARMA(1,1)	0,0156	0,0170	0,0171	0,0171
Naivný	0,0191	0,0236	0,0245	0,0238

Tabuľka 6: RMSE — rolling okno

Model	h=1	h=2	h=3	h=4
AR(1)	0,0158	0,0171	0,0173	0,0172
MA(1)	0,0158	0,0171	0,0173	0,0173
ARMA(1,1)	0,0157	0,0171	0,0173	0,0173
Naivný	0,0191	0,0236	0,0245	0,0238

Tabuľka 7: MAE — expanding okno

Model	h=1	h=2	h=3	h=4
AR(1)	0,0127	0,0136	0,0137	0,0136
MA(1)	0,0126	0,0135	0,0137	0,0136
ARMA(1,1)	0,0126	0,0136	0,0137	0,0136
Naivný	0,0161	0,0193	0,0201	0,0180

Tabuľka 8: MAE — rolling okno

Model	h=1	h=2	h=3	h=4
AR(1)	0,0158	0,0171	0,0173	0,0172
MA(1)	0,0157	0,0171	0,0173	0,0173
ARMA(1,1)	0,0158	0,0171	0,0173	0,0173
Naivný	0,0191	0,0236	0,0245	0,0238

ARMA modely vs. naivný model Všetky tri ARMA modely konzistentne prekonávajú naivný model pri všetkých horizontoch a oknách — RMSE naivného modelu je pri viac ako jednom kroku je o cca 40% vyššie.

Medzi ARMA modelmi Rozdiely sú minimálne — na 4 desatinné miesta takmer identické. ARMA(1,1) má mierne najnižšie RMSE pri h=1 v expanding okne, ale prakticky je to zanedbateľné.

Expanding vs. rolling okno Expanding okno dáva mierne lepšie výsledky — RMSE sú o niečo nižšie ako pri rolling okne. Dlhšia história teda pomáha, čo naznačuje že štruktúra rady je relatívne stabilná v čase. Rolling okno má výhodu adaptability na štrukturálne zmeny, avšak pri EUR/USD bez zjavného štrukturálneho zlomu má táto vlastnosť menší význam.

So zvyšujúcim sa horizontom RMSE rastie od h=1 po h=2, potom sa stabilizuje — čo je typické pre MA(1), kde predikcia pre h≥2 konverguje k priemeru a predikčná schopnosť sa ďalej nezlepšuje.

Na základe out-of-sample metrík je teoreticky najlepší ARMA(1,1) pri krátkom horizonte, ale rozdiel oproti MA(1) je zanedbateľný. Vzhľadom na úspornosť zostáva **MA(1)** celkovo najlepšou voľbou.

Rozdiel medzi in-sample a out-of-sample poradím modelov: in-sample vyhral MA(1) (najlepšie AIC/BIC), zatiaľ čo out-of-sample má mierne nižšie RMSE ARMA(1,1) pri krátkych horizontoch. Tento jav je bežný — model s viacerými parametrami môže lepšie zachytiť vzory v novej vzorke, aj keď in-sample je penalizovaný za komplexnosť. Rozdiely sú však minimálne a prakticky nepodstatné.

3.4 Naivný model a DM test

Naivný model (náhodná prechádzka) bol vo všetkých prípadoch výrazne horší ako ARMA modely — RMSE naivného modelu pri h=2 je 0.0236 oproti ≈ 0.0170 pre ARMA modely. Diebold-Marianov test formálne potvrdil, že MA(1) je štatisticky signifikantne lepší ako naivný model pri všetkých horizontoch a oknách, ak metrikou je RMSE:

Tabuľka 9: DM test — MA(1) vs. naivný model

h	Okno	DM štatistika	p-hodnota	Záver
1	Expanding	-3.487	0.0005	MA(1) lepší
2	Expanding	-3.877	0.0001	MA(1) lepší
3	Expanding	-3.465	0.0005	MA(1) lepší

h	Okno	DM štatistika	p-hodnota	Záver
4	Expanding	-2.287	0.0222	MA(1) lepší
1	Rolling	-3.320	0.0009	MA(1) lepší
2	Rolling	-3.730	0.0002	MA(1) lepší
3	Rolling	-3.372	0.0007	MA(1) lepší
4	Rolling	-2.239	0.0252	MA(1) lepší

3.5 Predikcia mimo vzorky — MA(1)

Graf predikcie mimo vzorky zobrazuje bodové predikcie MA(1) pre 2026/01 – 2026/04 spolu s 95%.ným predikčným intervalom. Bodová predikcia rýchlo konverguje k dlhodobému priemeru 0, čo odráža vlastnosť MA(1) — pamäť modelu je len jeden krok dozadu. Predikčný interval je pomerne široký (± 0.04), čo je typické pre menové kurzy s vysokou volatilitou. So zvyšujúcim sa horizontom sa interval rozširuje — dlhodobá predikcia kurzu je inherentne neistá.

