


Semestrálny projekt – Analýza CGM glykémie

Predmet: BPE_CARA 2026 – Časové rady

Autor: Mgr. Dana Kozáková



Obrázok 1: Uzavretý cyklus v inzulínovej pumpe

1. Úvod

Sledovanie glykémie bolo pre mňa každodennou záležitosťou „vďaka“ ochoreniu môjho syna. Už dávno som sa „hrabala“ v glykemických profiloch a neskôr keď prišli do praxe inzulínové pumpy, tak dát na skúmanie bolo naozaj dosť. Keď som po rokoch pochopila možnosti časových radov, voľba padla práve na takýto časový rad. Chcela som skúmať priamo synove krivky, ale zistila som, že teraz už softvér k inzulínovej pumpe raw-data neposkytuje. Tak som hľadala vhodné dáta a našla som štúdiu, kde sa snažili overiť, či tzv. uzavretá slučka (vtedy novinka) zlepšila glykemický profil pacientov.

Tento môj projekt analyzuje glykemický časový rad pacienta z klinickej štúdie iDCL Trial (Breton et al., 2021) s názvom *Klinický manažment a nastavenie parametrov kontrolovanej uzavretej slučky v systéme Control-IQ: Výsledky 6-mesačnej multicentrickej randomizovanej klinickej štúdie*. Kľúčovým zistením štúdie je, že čas v cieľovom rozsahu glykémie (TIR = time-in-range 70–180 mg/dL) sa celkovo nezlepšil, avšak u pacientov s vysokým HbA1c (> 7,5 %) sa TIR zvýšil (z 51,2 % na 57,7 %). Zjednodušene povedané: u diabetikov 1. typu sa sleduje najmä podiel času, kedy má pacient „správne glykémie“ a ideálnym stavom je, ak je to 100%. V spomenutej štúdii sa pumpy nastavovali podľa výsledkov pacientov. A to nastavenie malo ideálne viesť k zlepšeniu TIR.

Pre analýzu bol vybraný pacient s nadpriemernou glykémiou (GMI 7,79 %, TIR 53,5 %), u ktorého podľa štúdie „vo všeobecnosti“ malo nastať zlepšenie. Čiže očakávala som, že sa potvrdila štrukturálne zlomy, po nastavení sa zvýši TIR apod. Mojim cieľom bolo overiť prostredníctvom metód časových radov, či intervencie pumpy zanechali merateľné zmeny zachytiteľné štatistickými nástrojmi a pokúsiť sa ich vysvetliť v kontexte tejto témy.

Počas tvorby projektu som spolupracovala s AI, najmä Claude a AntigraVity spôsobom „sparring partner“, návrhom, diskusiou, validáciou, najmä pri generovaní správneho kódu v Pythone.


2. Dáta a metódy

2.1 Opis dát

CGM dáta pacienta č. 28 obsahujú 4515 hodinových pozorovaní priemernej glykémie (v mg/dl) za obdobie 31. 7. 2017 – 4. 2. 2018 (188 dní). Dáta boli predspracované v samostatnom skripte (01_select_patient.ipynb): nulové a chybné hodnoty boli nahradené hodnotou NaN pred agregáciou, chýbajúce hodiny (2,9 %) boli interpolované lineárne. Údaje

som transformovala na jednotky mmol/g, ktoré sú v Európe bežnejšie. V podstate je tento pacient mierne dekompenzovaný s neuspokojivou kompenzáciou diabetu. Priemerná hodnota je vysoká. Takmer polovicu času je v hyperglykémii bez hypoglykemických stavov.

Metrika	Hodnota
Počet pozorovaní	4 515
Priemer (mmol/l)	10,40
Medián (mmol/l)	9,62
SD (mmol/l)	3,52
Min / Max (mmol/l)	3,60 / 22,16
CV (%)	33,9
GMI / est. HbA1c (%)	7,79
TIR 70–180 mg/dL (%)	53,5
TBR <70 mg/dL (%)	0,1
TAR >180 mg/dL (%)	46,4



Obrázok 2: Hodinový CGM rad s vyznačenými intervenciami T2 a T13

2.2 Metódy

Analýza prebehla v piatich fázach:

- STL dekompozícia — rozklad radu na trend, sezónnosť a reziduá, vizualizácia denného profilu.
- SARIMA modelovanie — manuálny výber modelu pomocou AIC/BIC a Ljung-Box testu, out-of-sample predikcia a porovnanie s naivnými benchmarkmi (Diebold-Mariano test).
- Štrukturálne zlomy — Chow test v known breakpoints T2 a T13, endogénna detekcia algoritmom Binary Segmentation (Bai-Perron).
- GARCH(1,1) — modelovanie podmienenej volatility na reziduách SARIMA modelu.
- Grangerova kauzalita — VAR model na denných priemeroch deň/noc, F-test kauzality v oboch smeroch.


3. Analýza časových radov

3.1 Exploratívna analýza a STL dekompozícia

STL dekompozícia ($s=24$, $trend=199$) odhalila výraznú 24-hodinovú sezónnosť, výrazne rastúci trend po druhom nastavení (čas označený ako T13). V grafoch taktiež vidíme vyššiu variabilitu v neskoršom období. Priemerný denný profil zachytáva ranný nárast glykémie — ten by som skôr pripísala rannej rezistencii pri raňajkách, aj keď do úvahy môže pripadať aj tzv. syndróm briedenia. V dennom profile vidno jasnejšie večerný syndróm stmievania (t.j. nárast glykémie), ktorá pretrváva až do polnoci.




Obrázok 3: STL dekompozícia: trend, sezóna, reziduá



Obrázok 4: Priemerný denný profil $\pm$ SD s vyznačením noci]

3.2 Stacionarita radu

Pri ACF grafe vidíme veľmi pomalý pokles, silnú autokorelačnú závislosť. Okolo lagu 24 a 48 vidno mierne zvýšené lokálne maximum, čo predikuje 24-hodinovú sezónnosť. To zrejme súvisí s cirkadiánnym rytmom diabetika, pravdepodobnou pravidelnosťou v stravovaní ako aj prípadným nastavením inzulínových dávok. Pri PACF grafe vidíme výrazné prvé dva – tri lagy.



Obrázok 5: ACF a PACF (48 lagov)

ADF test zamietol nestacionaritu (štatistika $-8,89$, $p < 0,001$), zatiaľ čo KPSS test zamietol stacionaritu radu (štatistika $5,29$, $p = 0,01$). Tu je zdanlivý rozpor, je to teda nejednoznačné. Rad má dlhú pamäť alebo je trendovo stacionárny. Pre účely SARIMA modelovania pracujeme s pôvodným (nediferencovaným) radom (teda $d = 0$), čo potvrdzujú aj informačné kritériá fitovania modelov.

3.3 SARIMA modelovanie


SARIMA ukazuje, do akej miery sa dá glykémia predikovať z vlastnej histórie. V princípe s nejakou krátkodobou predikciou počítajú aj dnešné pumpy s uzavretým cyklom, lebo sa rozhodujú, aké množstvo inzulínu vydávajú, aby glykémia o hodinu bola v rámci odporúčaných hodnôt.

Vyskúšala som pár modelov s koeficientmi na základe ACF/PACF. Automatická detekcia trvala príliš dlho, takže som ju nakoniec nenechala dobehnúť.

Po zhodnotení parametrov som ako najlepší vybrala SARIMA(2,0,1)(1,0,1)[24]: dosahuje druhé najnižšie AIC (16 412) a ako jediný zo troch najlepších modelov spĺňa podmienku neautokorelovateľnosti reziduí (Ljung-Box $p = 0,20$). Všetky 3 najlepšie modely majú rovnakú sezónnu časť, líšia sa len nesezónnymi parametrami. Model s nižším AIC (SARIMA(2,0,2), AIC = 16 401) bol zamietnutý pre autokoreláciu reziduí (Ljung-Box $p = 0,02$). Do úvahy pripadala ešte SARIMA(1,0,1), ale nakoniec som sa rozhodla pre SARIMA(2,0,1) pre lepšiu interpretovateľnosť. Nesezónna AR(2) zložka modelu je klinicky interpretovateľná — glykemický „šok“ spôsobený príjmom potravy alebo bolusovou dávkou inzulínu pôsobí spravidla 1–2 hodiny. AR(2) tak zachytáva krátkodobú farmakodynamickú pamäť.

Model	AIC	BIC	LB Q(24)	LB p
SARIMA(2,0,2)(1,0,1)24	16 401	16 446	39,64	0,02
SARIMA(2,0,1)(1,0,1)24	16 412	16 450	29,59	0,20
SARIMA(1,0,1)(1,0,1)24	16 413	16 445	33,17	0,10

Diagnostika vybraného modelu: Jarque-Bera test zamietol normalitu reziduí (JB = 2 278,9, $p < 0,001$), čo naznačuje ťažké chvosty, vidno to aj na QQ plote reziduí. To zodpovedá klinickej realite extrémnych hypo- a hyperglykémii. ARCH-LM test (12 lagov) potvrdil prítomnosť ARCH efektov (LM = 249,2, $p < 0,001$), silne zamietol homoskedasticitu, čo opodstatňuje následnú GARCH analýzu.



Obrázok 6: Diagnostické grafy reziduí SARIMA(2,0,1)(1,0,1)24


3.4 Out-of-sample predikcia

Model som testovala tak, ako by reálne fungovala pumpa: predpovedať najbližších 24 hodín. SARIMA tu poráža obidva naivné benchmarky. Lenže keď som rozdiel preverila Dieboldovým-Marianovým testom, vyšla zaujímavá nuansa: SARIMA je **významne lepšia než sezónny naivný model** (ten len kopíruje včerajšok) ($DM = -3,07$, $p = 0,002$), ale **nie výrazne lepšia než triviálne „o hodinu to bude rovnaké ako teraz“** ($p = 0,075$). Pridaná hodnota modelu spočíva hlavne v tom, že pozná denný rytmus. A celková chyba (RMSE okolo 3,5 mmol/l) je tak či tak vysoká. Model nevidí to najdôležitejšie – kedy pacient jedol, koľko si pichol inzulínu, či sa hýbal.

Predikčná výkonnosť bola hodnotená na testovacej množine 336 hodín (14 dní) pomocou dvoch prístupov: statická predikcia celého horizontu a rolling predikcia (14 dní $\times$ 24 hodín, model refitovaný v každom okne).

Model	RMSE	MAE	MAPE (%)
SARIMA(2,0,1)(1,0,1) ₂₄	3,57	2,95	25,4
Naivný = „O hodinu rovnako“ (lag 1)	4,70	3,61	29,4
Sezónny naivný = „Ako včera“ (lag 24)	4,73	3,75	32,1

Rolling predikcia (14 okien $\times$ 24 h) dosahuje RMSE = 3,571, MAE = 2,950 a MAPE = 25,4 %. Rozdiel oproti naivnému (lag 1) nie je štatisticky signifikantný ($p = 0,075$), čo je typické pri vysoko autokorelovaných radoch. MAPE je pri CGM dátach potrebné interpretovať opatrne – nízke hodnoty glykémie (blízko hypoglykemického prahu) spôsobujú umelé nafúknutie percentuálnej chyby.



Obrázok 7: Predikcia vs. skutočnosť (posledných 14 dní)

3.5 Štrukturálne zlomy

Zmenili niečo úpravy pumpy?


Rozdelila som sledovanie na tri obdobia podľa intervencií. Ako bolo vidno už z exploratívneho grafu: pacient sa po 13. týždni **výrazne zhoršil**. Jeho čas v cieľovom rozsahu spadol zo 71 % na 39 % a priemerná glykémia vyskočila z 9,12 na 11,47. Tento individuálny výsledok je v kontraste so závermi paperu, kde sa u podskupiny s vysokým HbA1c prejavilo zlepšenie. U pacienta môžu zohrávať úlohu individuálne fyziologické faktory alebo suboptimálne nastavenie parametrov pumpy.

Obdobie	N (h)	Priemer (mmol/l)	SD (mmol/l)	TIR (%)	GMI (%)
Pred T2	322	8,69	2,78	74,2	7,05
T2 – T13	1 680	9,12	2,88	71,4	7,24
Po T13	2 513	11,47	3,62	39,0	8,25

Chow test v oboch known breakpoints potvrdil štatisticky signifikantné štrukturálne zlomy v AR(2) modeli:

Bod	Dátum	F-štatistika	p-hodnota	Záver
T2	14. 8. 2017	8,977	0,000006	Zamietnutie H0 — zlom
T13	23. 10. 2017	29,674	< 0,001	Zamietnutie H0 — zlom

Pred T2: CUSUM je v rámci hraníc, model je stabilný. Medzi T2 až T13: CUSUM ostáva v rámci hraníc, teda nezaznamenali sme výraznú zmenu strednej hodnoty po 2-týždňovej intervencii. Po T13 CUSUM začína výrazne rásť a prekračuje hornú hranicu. Pozitívny drift CUSUM po T13 znamená, že AR(2) model systematicky podpredikuje – skutočná glykémia je vyššia, ako model očakáva.




Obrázok 8: CUSUM plot: stabilita AR(2) modelu v čase

3.6 Modelovanie volatility — GARCH(1,1)

Na základe potvrdennej prítomnosti ARCH efektov bol na reziduách SARIMA modelu fitovaný GARCH(1,1) s nulovou strednou hodnotou (zero-mean). Model odhaduje podmienenú volatility (σ_t) — teda časovo premenlivú mieru nestability glykémie, ktorá nie je zachytená deterministickou časťou SARIMA modelu.

Obdobie	Priemerná podmienená volatility (σ)
Pred T2	1,613
T2 – T13	1,465
Po T13	1,479

Volatilita klesla po intervencii T2 a zostala nižšia. Aj ďalej zostala nižšia napriek tomu, že priemerná glykémia po T13 výrazne stúpla. To naznačuje, že pumpa zlepšila konzistenciu riadenia (menšie náhle výkyvy), avšak asi sa nastavila na príliš konzervatívnu hodnotu bazálneho inzulínu — glykémia bola stabilnejšia, no trvalo príliš vysoká.




Obrázok 9: CGM a podmienená volatility GARCH(1,1) s vyznačením T2 a T13

3.7 Grangerova kauzalita: deň vs. noc

Nakoniec som z dát vyrobila dva paralelné rady – priemernú dennú a priemernú nočnú glykémiu. A zisťovala, či sa ovplyvňujú. Rad bol rozdelený na denné priemery (6:00–21:59) a nočné priemery (22:00–5:59). Oba rady sú stacionárne (ADF: deň $p = 0,021$, noc $p < 0,001$). VAR model bol fitovaný s optimálnym rádom $\text{lag}=3$, určeným podľa AIC a HQIC kritéria.

Možno povedať, že **deň predpovedá noc, ale opačne to neplatí**. Aký bol pacient cez deň (jedlo, aktivita), to sa ovplyvňuje glykemický profil v noci; opačne to neplatí — nočná hladina už pre deň nič nového nepovedala nad rámec toho, čo o sebe deň „vie“ sám. Optimálny rád $\text{lag}=3$ je konzistentný s adaptačnou periódou algoritmu Control-IQ – podľa klinickej skúsenosti trvá pri zmene parametrov pumpy 2–3 dni, kým sa SW pumpy adaptuje na nové hodnoty glykémie a plne sa prejaví v glykemickom profile.

Lag	Deň → Noc (F)	Deň → Noc (p)	Noc → Deň (F)	Noc → Deň (p)
1	7,988	0,0052 **	1,192	0,276
2	3,721	0,0261 *	0,306	0,737
3	5,894	0,0007 ***	1,202	0,311



Obrázok 10: Denná vs. nočná glykémia v čase

4. Záver

Analýza CGM časového radu pacienta č. 28 z iDCL Trial priniesla niekoľko konzistentných štatistických zistení:

- SARIMA(2,0,1)(1,0,1)[24] adekvátne zachytáva krátkodobú (AR(2): 2–3) a 24-hodinovú sezónnu štruktúru glykémie. Model je signifikantne presnejší ako sezónny naivný benchmark (DM test, $p = 0,002$).
- Chow test potvrdil štatisticky signifikantné štrukturálne zlomy v oboch intervenčných bodoch T2 a T13, čo naznačuje, že úpravy parametrov pumpy mali merateľný štatistický efekt.
- Glykémia u tohto pacienta sa po T13 zhoršila napriek intervencii (TIR klesol z 74,2 % na 39,0 %). GARCH(1,1) analýza ukazuje, že volatilita klesla a zostala nižšia ako pred T2 — pumpa stabilizovala riadenie, ale na príliš vysokej glykemickej úrovni.
- Grangerova kauzalita (VAR $\text{lag}=3$) potvrdila jednosmerný vzťah: denná glykémia Granger-spôsobuje nočnú ($p < 0,001$ pre $\text{lag } 3$), ale nie naopak. Horizont 3 dní korešponduje s adaptačnou periódou algoritmu Control-IQ.

Obmedzenia projektu: MAPE nie je ideálna metrika pre CGM dáta z dôvodu citlivosti na nízke hodnoty glykémie; vhodnejšia by bola nejaká klinicky orientovaná metrika. Analýza sa vzťahuje na jediného pacienta – závery nie sú zovšeobecniteľné na populáciu. Dostupné dáta neumožňujú odlíšiť efekt intervencie od individuálnych fyziologických zmien. De facto neviem, čo je vlastne za týmto protikladným výsledkom. Intervencie a nastavenia inzulínu zdravotným personálom by za ideálnych okolností mali viesť k zlepšeniu. Ale z vlastnej skúsenosti viem, že sa to nie vždy podarí. Faktory diabetickej kompenzácie sú nevyspytateľné. Neznáme sú pre nás laikov aj vzorce a modely, ktoré stoja za výpočtami vhodnej dávky inzulínu v uzavretom cykle. Takto môžem iba s pomocou techník časových radov skúmať, analyzovať a vyhodnocovať rôzne aspekty týchto radov. Zároveň tieto metódy sa mi zdajú vhodné na vyhodnotenie prípadnej intervencie, či identifikáciu zvýšenej volatility, ktorá je taktiež nežiadúca ako vysoká stredná hodnota.

5. Použitá literatura

1. O'Malley G, Messer LH, Levy CJ, Pinsker JE, Forlenza GP, Isganaitis E, Kudva YC, Ekhlaspour L, Raghinaru D, Lum J, Brown SA; for the iDCL Trial Research Group. *Clinical Management and Pump Parameter Adjustment of the Control-IQ Closed-Loop Control System: Results from a 6-Month, Multicenter, Randomized Clinical Trial*. Diabetes Technology & Therapeutics. 2021;23(4):245–252. doi:10.1089/dia.2020.0472. PMID: 33155824.
2. Brown SA, Kovatchev BP, Raghinaru D, Lum JW, et al. *Six-Month Randomized, Multicenter Trial of Closed-Loop Control in Type 1 Diabetes*. N Engl J Med. 2019;381(18):1707–1717. (DCLP3, NCT03563313)
3. NIDDK Central Repository — DCLP3: <https://repository.niddk.nih.gov/studies/dclp3/> ; dataset: <https://public.jaeb.org/dataset/573>